

XP Educação
Relatório do Desafio Final

**Desafio Final - Bootcamp: Analista
em Segurança da Informação e
Cibersegurança IA Expert**

Arthur Gustavo Macena Moreira

2026



1. Introdução e Preparação da Base de Dados

Este projeto documenta o desenvolvimento de um sistema automatizado para a SecureMail Corp., focado em classificar e-mails e identificar tentativas de *phishing* utilizando técnicas de Processamento de Linguagem Natural (NLP) e Machine Learning.

Como a base de dados original contava com apenas 10 registros, o que inviabilizaria o treinamento adequado de qualquer algoritmo de inteligência artificial, o primeiro passo estratégico foi realizar o *Data Augmentation*. Utilizando um script Python com a biblioteca random, a base foi expandida de forma sintética para cerca de 100 registros. Esta abordagem garantiu um volume mínimo aceitável para que o modelo pudesse aprender padrões linguísticos e extrair correlações significativas.

2. Estratégia de Pré-processamento

O pré-processamento de texto é a fase mais crítica em NLP, pois algoritmos matemáticos não interpretam texto puro. A estratégia adotada seguiu um *pipeline* rigoroso de limpeza e transformação:

- **Limpeza Básica e NLP (spaCy):** Todo o texto foi convertido para minúsculas e teve sua pontuação removida via expressões regulares (*re*). Em seguida, utilizou-se o modelo de linguagem *pt_core_news_sm* da biblioteca spaCy. A escolha do spaCy justifica-se pela sua eficiência e suporte robusto nativo ao idioma português, permitindo a execução precisa de duas tarefas fundamentais: a remoção de *stopwords* (palavras de conexão sem valor semântico para a classificação) e a **lematização** (redução das palavras à sua raiz, agrupando variações como "atualize", "atualização" e "atualizado" em um único padrão).
- **Vetorização (TF-IDF):** Para converter o texto processado em matrizes numéricas, optou-se pelo TfidfVectorizer da biblioteca scikit-learn. Diferente de uma simples contagem de palavras, o TF-IDF penaliza termos que aparecem em quase todos os e-mails e dá maior peso a palavras raras, mas que são fortes indicadores de *phishing* (ex: "senha", "urgente", "bloqueio").
- **Separação de Dados:** A base foi dividida utilizando o *train_test_split* com o parâmetro stratify. Isso garantiu que exatamente 50% dos dados fossem separados para teste de forma completamente isolada do treinamento, mantendo a proporção exata entre as classes (legítimo vs. phishing) em ambos os conjuntos.

3. Seleção do Modelo


O algoritmo escolhido para a tarefa foi o **Naive Bayes** (especificamente a implementação MultinomialNB). A escolha baseia-se no fato de que o Naive Bayes é o modelo probabilístico clássico e historicamente mais bem-sucedido para filtragem de spam e classificação de textos textuais discretos. Ele assume independência entre as palavras calculando a probabilidade de um e-mail pertencer à classe de *phishing* dado o seu vocabulário, operando com extrema velocidade e alta performance mesmo com conjuntos de dados relativamente pequenos.

4. Avaliação e Análise da Matriz de Confusão

O modelo foi submetido à carga de teste (invisível durante o treinamento) e obteve um desempenho muito bom:

- **Acurácia:** 0.96 (96% de acertos globais).
- **F1-Score:** 0.96, indicando um excelente equilíbrio harmônico entre precisão e recall.

Abaixo, a Matriz de Confusão detalha o comportamento preditivo da IA:



Interpretação dos Resultados:

O dado mais relevante para um sistema de cibersegurança nesta matriz é o **Recall de 1.00 (100%)**. O modelo identificou corretamente todos os 24 e-mails de *phishing* (Verdadeiros Positivos), não deixando nenhuma ameaça passar despercebida (Zero Falsos Negativos).

Houve 2 casos em que e-mails legítimos foram classificados como ameaças (Falsos Positivos), resultando em uma **Precisão de 0.92**. Em arquiteturas de segurança, esta é a margem de erro preferível: é infinitamente mais seguro reter temporariamente um e-mail corporativo legítimo para verificação manual do que permitir que um único artefato malicioso alcance a caixa de entrada do usuário.

Resumo das Métricas Gerais

Métrica	Valor
Acurácia	0.96
Precisão	0.92
Recall	1.00
F1-Score	0.96

5. Aplicações Práticas e Melhorias Futuras

Aplicações Práticas:

No cenário corporativo atual, especialmente nas rotinas de Gestão de Identidades e Acessos (IAM), a engenharia social é o vetor primário para o comprometimento de senhas e tokens de autenticação. A aplicação prática direta deste modelo seria sua integração via API aos *gateways* de e-mail corporativo. Ao atuar como uma camada de proteção automatizada e silenciosa, a ferramenta reduz drasticamente a superfície de ataque, protegendo as identidades dos colaboradores antes mesmo que eles precisem tomar uma decisão sobre clicar ou não em um link suspeito.

Melhorias Futuras: Para evoluir o sistema em futuras iterações, propõe-se:

1. **Expansão Massiva do Dataset:** Substituir a base sintética por milhares de e-mails reais anonimizados para capturar nuances linguísticas mais sofisticadas.
2. **Transição para Redes Neurais:** Implementar modelos de Deep Learning baseados em arquiteturas *Transformer* (como BERT ou LLMs focados em segurança), que conseguem capturar não apenas a frequência das palavras, mas o contexto e a intenção semântica completa das frases estruturadas em ataques de *Spear Phishing*.